Leitfaden zur ILV

Daten und Statistik

Informationstechnik und System-Management

FH-Salzburg

Univ.Doz.Dr. Stefan Wegenkittl & Dr. Simon Kirchgasser, MSc.[1]

Version: 25. Februar 2025

[1] Verwendung, Nachdruck und Veröffentlichung – auch in Ausschnitten – außerhalb der Fachhochschule Salzburg nur mit ausdrücklicher Genehmigung der Autoren.

Vorwort

Ziel der Lehrveranstaltung ist - in Ergänzung zur Wahrscheinlichkeitsrechnung im Wintersemester - die Vermittlung eines sicheren Umgangs mit Daten im Sinne der beschreibenden Statistik, die Befähigung zur Analyse von Korrelationen und Regressionsmodellen in mehrdimensionalen Daten sowie die Grundlagen der Schätztheorie für Punkt- und Intervallschätzer. Die erhaltenen Ergebnisse werden interpretiert und graphisch aufbereitet.

Dieser Leitfaden erhebt in keinster Weise Anspruch auf Vollständigkeit. Vielmehr soll das Ineinandergreifen der oben erwähnten Gebiete an ausgewählten Beispielen gezeigt werden und eine kleine Methoden- und Formelsammlung als Unterstützung den für Vorlesungs- und Übungsbetrieb entstehen. Weiterführende Literatur wird in der IVL besprochen.

Für Anmerkungen und Korrekturen sind die Autoren[1] jederzeit dankbar.

[1] Stefan.Wegenkittl@fh-salzburg.ac.at

Inhaltsverzeichnis

1 Einleitung **4**

2 Grundbegriffe der beschreibenden Statistik **8**

2.1 Daten, Stichproben und Merkmale 8

2.1.1 Skalenniveau 9

2.2 Lageparameter 9

2.2.1 Median 9

2.2.2 Empirischer Mittelwert, Mean, Mean Value, Average 9

2.2.3 Quantile 10

2.3 Streuungsmaße 10

2.3.1 Varianz und Standardabweichung 10

2.3.2 Quartilsabstand 11

3 Stichproben mehrdimensionaler Merkmale und Korrelationsanalyse **12**

3.1 Kontingenztafel und Visualisierung 12

3.2 Graphische Analyse 13

3.3 Korrelation - Stärke und Richtung des linearen Zusammenhangs 14

3.4 Regression: Modellanpassung 16

3.4.1 Umsetzung mit Python 17

3.4.2 Weitere Modelle für lineare Regression 18

3.4.3 Nichtlineare Regression 20

3.4.4 Ausblick: Mehrdimensionale Regression 21

4 Parameterschätzung und Konfidenzintervalle **23**

4.1 Parameterschätzung 23

4.1.1 Schätzer für die Erfolgswahrscheinlichkeit $\hat{p}$ 23

4.1.2 Allgemeiner Fall 24
4.1.3 Wichtige Schätzer für Parameter 25
4.1.4 Wichtige Schätzer für Momente 25
4.2 Konfidenzintervalle 26

5 Ausblick: Einführung in die schließende Statistik **29**
5.1 Formulierung von Hypothesen 29
5.2 Entscheidungsregel und Bezeichnungen 30

6 Tabellen **36**
6.1 Standardnormalverteilung $N_{0,1}$: $\Phi(x)$ 36
6.2 Student-T-Verteilung T_n: $F^{-1}(p)$ 37

Kapitel 1

Einleitung

"Wenn jemand von den Fertigkeiten und Künsten die Rechenkunst, die Messkunst und die Kunst des Wägens wegnimmt, so bleibt, um es offen zu sagen, nur etwas übrig, was fast minderwertig ist [...]. Es bleibt nichts anderes übrig, als ein Errarten, ein Schließen durch Vergleichen und ein Schärfen der Sinneswahrnehmung durch Erfahrung und durch eine gewisse Übung, wobei man die - von vielen als Künste titulierten - Fähigkeiten des geschickten Vermutens benützt, die durch stete Handhabung und mühevolle Arbeit herangebildet werden."

Dieser Textausschnitt aus dem *Philebos* des griechischen Philosophen PLATON ist die erste erhaltene Niederschrift dessen was wir heute unter **Stochastik** verstehen. Damals als 'Fähigkeit des geschickten Vermutens' bezeichnet, versteht man heute darunter den Oberbegriff der mathematischen Gebiete *Wahrscheinlichkeitstheorie* und *Statistik*, welche sich mit der Beschreibung von diversen Zufallsphänomen beschäftigen. Im ersten Teilgebiet, der Wahrscheinlichkeitstheorie, beschreibt und analysiert man zufällige Prozesse welche über feste bzw als bekannt angegebene Wahrscheinlichkeiten definiert sind. Die entwickelten Methoden stellen hierbei die formale mathematischen Grundlage für die theoretische Untersuchung statistischer Verfahren. Diese Verfahren, welche im Teilgebiet der Statistik zusammengefasst werden, verwendet man um aus beobachteten Daten Schlüsse über unbekannte Wahrscheinlichkeiten und/oder deren Auswirkungen in realen Situation zu ziehen.

Die Begriffe 'Stochastische Modellbildung' und 'Wahrscheinlichkeitsrechnung' kann man dem Gebiet der Wahrscheinlichkeitstheorie zuordnen. Beide Begriffe decken im Wesentlichen die Kerninhalte dieser LVA ab, allerdings mit einem feinen Unterschied: Während die 'Stochastische Modellbildung' eine eher formalere Betrachtung der Inhalte erlaubt, liefert die 'Wahrscheinlichkeitsrechnung' einen eher praktisch orientierten Zugang.

Die Wahrscheinlichkeitsrechnung hat sich historisch aus der Glücksspielrechnung entwickelt und damit von Beginn an praktische Fragestellungen untersucht. Berühmt ist etwa das Problem der Aufteilung eines Wetteinsatzes bei Abbruch eines Glücksspieles. Hier geht es um die Frage, wie man Fairness in diesem Zusammenhang formulieren, und auch konkret berechnen kann. Ausgehend von der Analyse des Verhaltens von einfachen Zufallsexperimenten (Stichwort "Würfeln") wird so der Bogen schnell zu modernen Anwendungen gespannt: Modelliert man durch partielles Unwissen generiertes quasi-zufälliges Verhalten (etwa die Entwicklung eines Börsenindex) mithilfe der Wahrscheinlichkeitsrechnung, so lassen

sich ideale Strategien, faire Preise und ähnliche Fragestellungen im Rahmen der Theorie präzisieren und beantworten.

Moderne Zufallsexperimente finden sich beispielsweise in den Wirtschaftswissenschaften, in der Kryptographie und in der Signalverarbeitung. Besonders dynamisch haben sich jedoch die Bereiche Data Science und Machine Learning, und damit die sogenannte künstliche Intelligenz, kurz KI, entwickelt.

Die Schnittstelle zwischen konkreten Daten aus Experimenten und den Modellen der Wahrscheinlichkeitsrechnung bildet historisch die Statistik. In Form der sogenannten beschreibenden Statistik extrahiert sie Kennzahlen aus den Daten und hilft dadurch und durch geeignete Visualisierungen beim Verständnis der Daten. Dort wo mittels der Wahrscheinlichkeitsrechnung und deren Modellen auch Schlussfolgerungen aus den Daten (der Stichprobe) auf die gedachte Gesamtheit gezogen werden, spricht man von schließender Statistik - bekanntestes Beispiel sind statistische Tests zur Differenzierung von zufälligem Rauschen und Information etwa im Bereich der Medizin. Auch die Regressionsrechnung beziehungsweise Modellanpassung fällt je nach Einsatzbereich (graphische Beschreibung oder Vorhersage) in eine der beiden Kategorien der Statistik.

Aus der Statistik hat sich die Data Science entwickelt, deren Ziel die Extraktion von Wissen oder Information aus Daten ist. Auch in der Data Science werden die Basismodelle aus der Wahrscheinlichkeitsrechnung verwendet um die angewandten Methoden, Algorithmen und Prozesse zu analysieren und zu verstehen.

Ein kurzes Beispiel zur Veranschaulichung der Zusammenhänge: Gegeben seien folgende Daten (Lebensdauern von techn. Bauteilen in Jahren)

0.14 0.27 0.43 0.68 0.81 1.14 1.45 1.82 2.36 2.53 2.90 3.45 4.51 5.12 5.68 7.84

Die **beschreibende** oder **deskriptive Statistik** versucht mittels geeigneter Kenngrößen oder speziellen graphischen Darstellungen die wesentlichen Merkmale einer solchen Stichprobe zu beschreiben. Als einfaches Beispiel sei hier der **Mittelwert** erwähnt welcher für obige Daten eine mittlere Lebensdauer von 2.5706 Jahren liefert. Die bekannteste graphische Methode ist sicherlich das **Histogramm** welches die relativen Anteile der Daten für bestimmte Intervalle angibt: Abbildung 1.1 zeigt (von links nach rechts) eine zu grobe, richtige und zu feine Einteilung der Daten in Klassen und deren Visualisierung mittels Histogrammen.

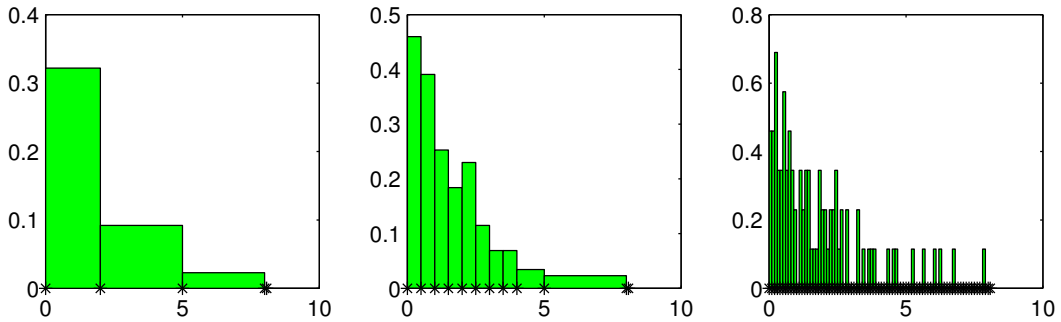

Abbildung 1.1: Histogramme. Auf der X-Achse ist die Lebensdauer der 87 Glühbirnen aufgetragen.

Die Wahrscheinlichkeitsrechnung könnte nun ein Modell für diese Daten liefern, etwa in Form der Ex-

ponentialverteilung. Diese Verteilung beschreibt in Abhängigkeit eines Parameters λ, wie wahrscheinlich das Auftreten von Werten in bestimmten Größenordnungen ist. Mittels Parameterschätzung kann die Exponentialverteilung an die vorliegende Stichprobe angepasst werden. Konkret würde etwa λ als Kehrwert des Mittelwertes mit 0.389 festgesetzt werden. Nun kann etwa eine Vorhersage für die Wahrscheinlichkeit des Auftretens von extrem hohen Werten getroffen werden.

Wird das technische Bauteil geändert und eine neue Stichprobe gezogen, so kann mittels eines statistischen Tests im Rahmen der schließenden Statistik die Frage untersucht werden, ob sich die Lebensdauern geändert haben oder nicht - natürlich nur im Rahmen der durch den Zufallscharakter der Untersuchung möglichen Irrtumswahrscheinlichkeit.

Mittels Verfahren der Data Science könnten weiterführende Zusammenhänge zwischen den Produktionsbedingungen und der individuellen Produktlebensdauer untersucht werden und zu einer automatischen Optimierung führen. Die digitale Transformation hat in vielen Bereichen des wirtschaftlichen und sozialen Lebens digitale Datenquellen entstehen lassen (etwa Sensoren an den Produktionsmaschinen), die eine solche Anwendung von Wahrscheinlichkeitsrechnung möglich machen und dadurch Wettbewerbsvorteile entstehen lassen.

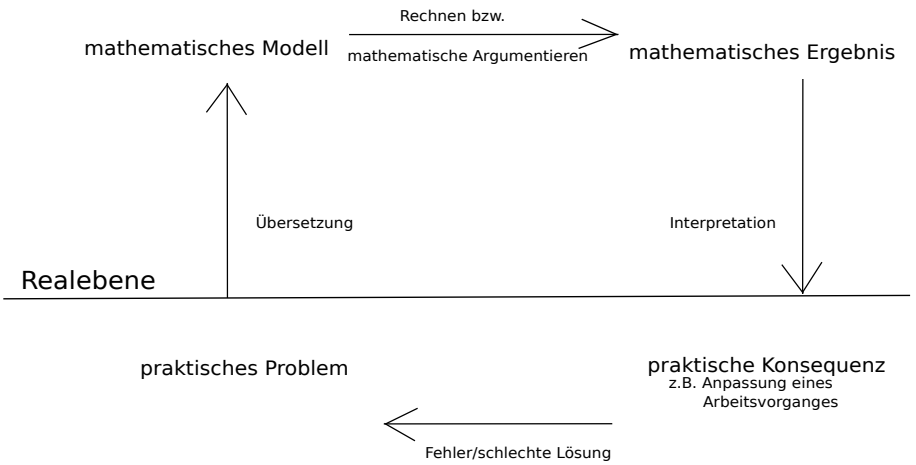

Abbildung 1.2: Wissenschaftlich mathematische Analyse eines Problems, *Galileo Galilei* (1564 - 1642)

Unabhängig davon welcher Anwendungsfall zutrifft, ist es gerade im Themengebiet der Stochastik/Wahrscheinlichkeitsrechnung von äußerster Bedeutung, sich bewusst zu machen, dass bei jeglichen Zufallsexperimenten ein Wechsel zwischen realen Beobachtungen und deren mathematischen Beschreibung stattfindet. In der folgenden Abbildung 1.2 ist dies veranschaulicht.

Man erkennt, dass ein gegebenes, reales Problem zunächst in mathematische Sprache übertragen werden muss. Die anschließende Lösungssuche findet in unserem Fall mit Hilfe von Methoden der Wahrscheinlichkeitsrechnung eine mögliche Lösung. Diese muss nach einer Rückübersetzung in die 'Realebene' erst auf Plausibilität überprüft werden. Sofern diese nicht positiv abgeschlossen werden kann, muss die mathematische Analyse des Problems erneut beginnen, da möglicherweise die Modellannahmen der gewählte Verteilung oder der Grundraum nicht sorgfältig genug gewählt worden sind.

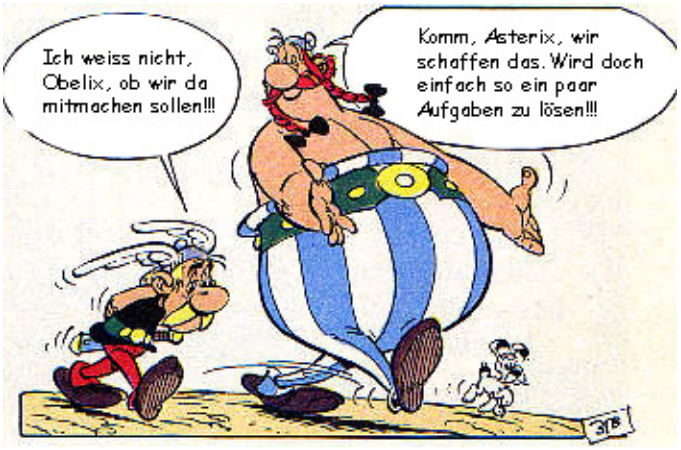
Ich weiss nicht, Obelix, ob wir da mitmachen sollen!!!
Komm, Asterix, wir schaffen das. Wird doch einfach so ein paar Aufgaben zu lösen!!!

Kapitel 2

Grundbegriffe der beschreibenden Statistik

2.1 Daten, Stichproben und Merkmale

Sei $x_1, x_2, \ldots, x_n$ eine Stichprobe (sample) der Größe n (sample size). Diese Stichprobe beschreibt ein **Merkmal** einer **Population**. Die Werte die dabei auftreten können heißen Merkmalswerte oder auch Merkmalsausprägungen (MAen) (manchmal auch kurz einfach Merkmale genannt). Wichtig für uns:

a) diskrete Merkmale (Bsp.: Augenzahl beim Würfeln). Die absolute Häufigkeit einer MA mit

$$H_i := \#\{1 \leq j \leq n \ : \ x_j = i\}$$

bezeichnet, die relative Häufigkeit mit

$$h_i := \frac{1}{n} \#\{1 \leq j \leq n \ : \ x_j = i\}$$

b) stetige/kontinuierliche Merkmale (Bsp.: Körpergröße in einer Menge von Personen). Die Menge der MAen ist hier ein Intervall (Teilmenge der reellen Zahlen). Meistens werden solche Merkmale in Klassen $K_1, \ldots, K_N$ eingeteilt, wobei jede Klasse wieder ein Interval ist: $K_i = [l_i, r_i)$. Man nennt l_i und r_i die Klassengrenzen und definiert den Klassenmittelpunkt $m_i = \frac{l_i + r_i}{2}$. Die absolute Klassenhäufigkeit wird mit

$$H_i := \#\{1 \leq j \leq n \ : \ x_j \in K_i\}$$

bezeichnet, die relative Häufigkeit erhält man wieder durch Division durch n.

Es gilt:

$$\forall i : 0 \leq h_i \leq 1 \qquad \sum_{i=1}^{N} h_i = 1 \qquad \sum_{i=1}^{N} H_i = n$$

Daten können als (ungeordnete) Stichprobe $x_1, x_2, \ldots, x_n$, oder als Häufigkeitstabellen zu MAen oder als

Häufigkeitstabellen zu Klassen vorliegen. Achtung: In den letzten beiden Fällen ist die Information über die Reihenfolge der Daten nicht mehr vorhanden. Bei Klassen findet zusätzlich eine Diskretisierung statt (die genauen Werte gehen verloren).

2.1.1 Skalenniveau

Je nach Art und Eigenschaften eines Merkmals bzw. je nachdem, welche Vorschriften bei seiner Messung eingehalten werden, lassen sich verschiedene Stufen unterscheiden. Das Skalenniveau bestimmt, welche mathematischen Operationen bei der Verarbeitung zulässig sind. Das Skalenniveau gibt keine Auskunft darüber, ob eine Variable diskret oder stetig ist. Einzig bei der Nominalskalierung ist das Merkmal immer diskret.

Skalenniveau	Messbare Eigenschaften	mögliche Operationen	Beispiel	Messgrößen
Nominalskala	Rein qualitativ, somit nur Häufigkeit	$=, \neq$	PLZ, Kennzeichen, Blutgruppe, Geschlecht	Modus
Ordinalskala	Häufigkeit und Rangfolge	$=, \neq, <, >$	Schulnoten, Dienstrang, Krebsstadien	Median
Intervallskala	Häufigkeit, Rangfolge, Abstand	$=, \neq, <, >, +, -$	Datum, Temperatur in Celsius	Arithmetisches Mittel
RationalSkala	Häufigkeit, Rangfolge, Abstand, Nullpunkt	$=, \neq, <, >, +, -, \cdot, :$	Alter, Temperator in Kelvin, Preis, Menge	Geometrisches Mittel

2.2 Lageparameter

Lageparameter charakterisieren den Wertebereich der Stichprobe durch Angabe einer einzigen Zahl.

2.2.1 Median

Es sei $x_{(1)}, \ldots, x_{(n)}$ die geordnete Stichprobe (also die Werte $x_1, \ldots, x_n$ so umsortiert, dass gilt: $x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$). Der Median oder Zentralwert

$$\tilde{x} = \begin{cases} x_{(i)} & \text{mit } i = \frac{n+1}{2} \quad : \quad n \text{ ungerade} \\ \frac{1}{2}(x_{(i)} + x_{(i+1)}) & \text{mit } i = \frac{n}{2} \quad : \quad n \text{ gerade} \end{cases}$$

verhält sich gegenüber Ausreißern stabiler als der Mittelwert. Interpretation auch: Ein zufällig aus der Stichprobe gewählter Wert wird in der Hälfte der Fälle unter bzw. über dem Median liegen (gut für Wetten aller Art!).

2.2.2 Empirischer Mittelwert, Mean, Mean Value, Average

$$\bar{x} := \frac{1}{n} \sum_{i=1}^{n} x_i$$

Beschreibt jenen Wert, den man bei zufälligem Ziehen aus der Stichprobe im Mittel erwarten würde. Interpretation (ohne Beweis) auch: jener Wert, bei dem der mittlere quadratische Abstand zu den Werten

der Stichprobe minimal ist. Berechnung aus Häufigkeitstabellen:

$$\text{a)} \quad \bar{x} := \sum_{i=1}^{N} a_i h(a_i) \quad \text{b)} \quad \bar{x} := \textstyle\sum_{i=1}^{N} m_i h(K_i)$$

Es gilt: Skaliert man eine Stichprobe mit der linearen Funktion $y = a \cdot x + b$, so gilt für die skalierte Stichprobe $y_1 = a \cdot x_1 + b, \ldots, y_n = a \cdot x_n + b$: $\bar{y} = a \cdot \bar{x} + b$. Somit kann beispielsweise ein Temperaturmittelwert leicht von Celsius in Fahrenheit umgerechnet werden, dazu sind die Ausgangsdaten nicht nötig.

2.2.3 Quantile

Analog zum Median ("die Hälfte der Daten liegt unter dem Median") wird das α-Quantil $\tilde{x}_\alpha$ für $0 < \alpha < 1$ definiert:

$$\tilde{x}_\alpha = \begin{cases} x_{(i)} & \text{mit } i = \lceil n \cdot \alpha \rceil \quad : \quad n \cdot \alpha \text{ ist keine ganze Zahl} \\ \frac{1}{2}(x_{(i)} + x_{(i+1)}) & \text{mit } i = n \cdot \alpha \quad : \quad \text{sonst} \end{cases}$$

Interpretation: $[n \cdot \alpha]$ der Daten sind kleiner als $\tilde{x}_\alpha$.

Speziell nennt man $\tilde{x}_{1/2}$ den Median, $\tilde{x}_{1/4}$ das untere, und $\tilde{x}_{3/4}$ das obere Quartil, und $Q_A := \tilde{x}_{3/4} - \tilde{x}_{1/4}$, den Quartilsabstand (s.u.).

2.3 Streuungsmaße

Streuungsmaße charakterisieren die Variabilität der Daten in der Stichprobe.

2.3.1 Varianz und Standardabweichung

Die Varianz (variance) ist die mittlere quadratische Abweichung der Daten vom Mittelwert, wobei die Mittelung bei sehr kleinen Stichproben manchmal mit n, i.a. jedoch mit $n - 1$ vorgenommen wird:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2 \right)$$

Die Standardabweichung (mean deviation) ist die Wurzel aus der Varianz und wird mit s oder σ bezeichnet:

$$\sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2}$$

Berechnung aus Häufigkeitstabellen:

$$s^2 = \frac{n}{n-1} \sum_{i=1}^{N} h(a_i) \cdot (a_i - \bar{x})^2$$

Bei Klassen statt der a_i die Klassenmittelpunkte m_i verwenden.

Es gilt: Skaliert man eine Stichprobe mit der linearen Funktion $y = a \cdot x + b$, so gilt für die skalierte Stichprobe $y_1 = a \cdot x_1 + b, \ldots, y_n = a \cdot x_n + b$: $s_y^2 = a^2 \cdot s_x^2$. Wie muss daher die Umrechnung einer Varianz von Celsius in Farenheit aussehen?

2.3.2 Quartilsabstand

Der Quartilsabstand $Q_A := \tilde{x}_{3/4} - \tilde{x}_{1/4}$ ist ebenfalls ein Streuungsmaß und findet seine Anwendung vor allem bei sog. Boxplots, siehe Abbildung 2.1. Die Box reicht vom unterem zum oberen Quartil und wird durch den Median geteilt. Die "whiskers" (kurze Linien am oberen und unteren Ende des Plots) zeigen den Bereich der restlichen Daten an. Gibt es jedoch Daten die von den Begrenzungen der Box aus gesehen um mehr als $1.5 \cdot Q_A$ nach unten oder nach oben abweichen so werden diese Daten "Ausreißer" (outliers) genannt und sind im Boxplot durch kleine Kreuze markiert. Die Whiskers geben in diesem Fall den eineinhalbfachen Quartilsabstand vom unteren bzw. oberen Ende der Box an.

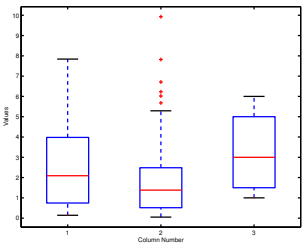

Abbildung 2.1: Boxplots.

Kapitel 3

Stichproben mehrdimensionaler Merkmale und Korrelationsanalyse

Beobachtungsergebnisse, bei denen an jeder Einheit (Messung, Beobachtung) 2 oder mehr Merkmale kontrolliert werden, bilden die Grundlage für Korrelationsanalysen. Dabei sollen mögliche stochastische ("korrelative") Zusammenhänge gefunden und beschrieben werden. Im Gegensatz zu "funktionalen" Zusammenhängen weichen die Daten dabei von den durch das Modell beschriebenen Vorhersagen durch Streuung ab.

Der einfachste Fall ist eine 2-dimensionale Stichprobe vom Umfang n mit den Wertpaaren (x_1, y_1), ..., (x_n, y_n) (Die x_i sind Messungen des ersten Merkmales X, die y_i die des zweiten, Y). Als Beispiel betrachten wir X=Geschwindigkeit, Y=Bremsweg, und vermuteten als korrelativer Zusammenhang: längerer Bremsweg bei höherer Geschwindigkeit. Zunächst können die beiden Merkmale voneinander unabhängig mit den bereits bekannten Methoden analysiert und beschrieben werden (Klasseneinteilung, Häufigkeiten, Mittelwert und Streuung für jedes Merkmal).

Um darüber hinaus Korrelationen zu analysieren, werden die Daten zunächst visualisiert. Man kann dabei bei diskreten oder bereits in Klassen eingeteilte Daten klassische Kontingenztafeln als Grundlage verwenden, oder aber bei stetigen Daten sogenannte Streuplots anfertigen.

3.1 Kontingenztafel und Visualisierung

Will man das gemeinsame Auftreten von bestimmten MAen in der Stichprobe beschreiben, so wird nach erfolgter Klasseneinteilung eine Kontingenztafel erstellt. Die Kontingenztafel enthält die relativen h_{ij} oder absoluten H_{ij} Häufigkeiten für das Auftreten der MAen oder Klassen i und j in der Stichprobe.

Für MAen a_i, $1 \leq i \leq l$ und b_j, $1 \leq j \leq m$ und Klassen definiert man:

$$\text{a)} \qquad h_{ij} = \frac{1}{n} H_{ij} = \frac{1}{n} \#\{1 \leq k \leq n : x_k = a_i, y_k = b_j\}$$

$$\text{b)} \qquad h_{ij} = \frac{1}{n} H_{ij} = \frac{1}{n} \#\{1 \leq k \leq n : x_k \in K_i, y_k \in K_j\}$$

	b_1	b_2	$\cdots$	b_m	Σ
a_1	H_{11}	H_{12}	$\cdots$	H_{1m}	$H_{1.}$
a_2	H_{21}	H_{22}	$\cdots$	H_{2m}	$H_{2.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
a_l	H_{l1}	H_{l2}	$\cdots$	H_{lm}	$H_{l.}$
Σ	$H_{.1}$	$H_{.2}$	$\cdots$	$H_{.m}$	n

	b_1	b_2	$\cdots$	b_m	Σ
a_1	h_{11}	h_{12}	$\cdots$	h_{1m}	$h_{1.}$
a_2	h_{21}	h_{22}	$\cdots$	h_{2m}	$h_{2.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
a_l	h_{l1}	h_{l2}	$\cdots$	h_{lm}	$h_{l.}$
Σ	$h_{.1}$	$h_{.2}$	$\cdots$	$h_{.m}$	1

Tabelle 3.1: Kontingenztabellen

Tabelle 3.1 zeigt eine Kontingenztafel für MAen. Dabei nennt man $H_{i.} = \sum_{j=1}^{m} H_{ij}$ **absolute Randhäufigkeit**, und $h_{i.} = \sum_{j=1}^{m} h_{ij}$ **relative Randhäufigkeit**, die Werte $H_{i.}$ ergeben dann die Randverteilung des ersten Merkmales. In analoger Weise erhält man die Randverteilung für das zweite Merkmal, $H_{.j}$. Klarerweise entsprechen diese Werte genau den Häufigkeiten welche man bei der isolierten Analyse der einzelnen Merkmale erhält.

Die Kontingenztabelle kann bei Bedarf auch in Form einer 3-D Balkengraphik oder in 2D Plots dargestellt werden. Abbildung 3.1 zeigt ein Beispiel mit konkreten Zahlen aus der folgenden Datenmatrix:

	$[0,1[$	$[1,2[$	$[2,3[$	$[3,4[$	Σ
$[0,1[$	0.596	0.106	0.050	0.014	0.766
$[1,2[$	0.138	0.036	0.010	0	0.184
$[2,3[$	0.026	0.008	0	0	0.034
$[3,4[$	0.010	0.006	0	0	0.016
Σ	0.770	0.156	0.060	0.014	1

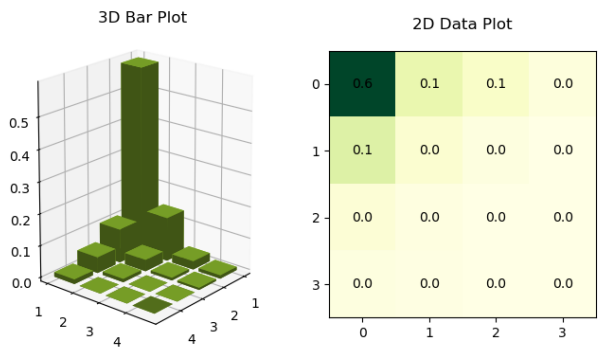

Abbildung 3.1: 3-D Balkengraphik und 2D Visualisierung

3.2 Graphische Analyse

Das Streudiagramm (Englisch: scatterplot) stellt die Daten der Stichprobe als Punkte dar. Die Achsen der Graphik entsprechen den beiden Merkmalen, wobei unter Umständen eine geeignete (auch nicht-lineare) Skalierung notwendig ist um einen möglichst einfachen Zusammenhang klar erkenntlich zu machen.

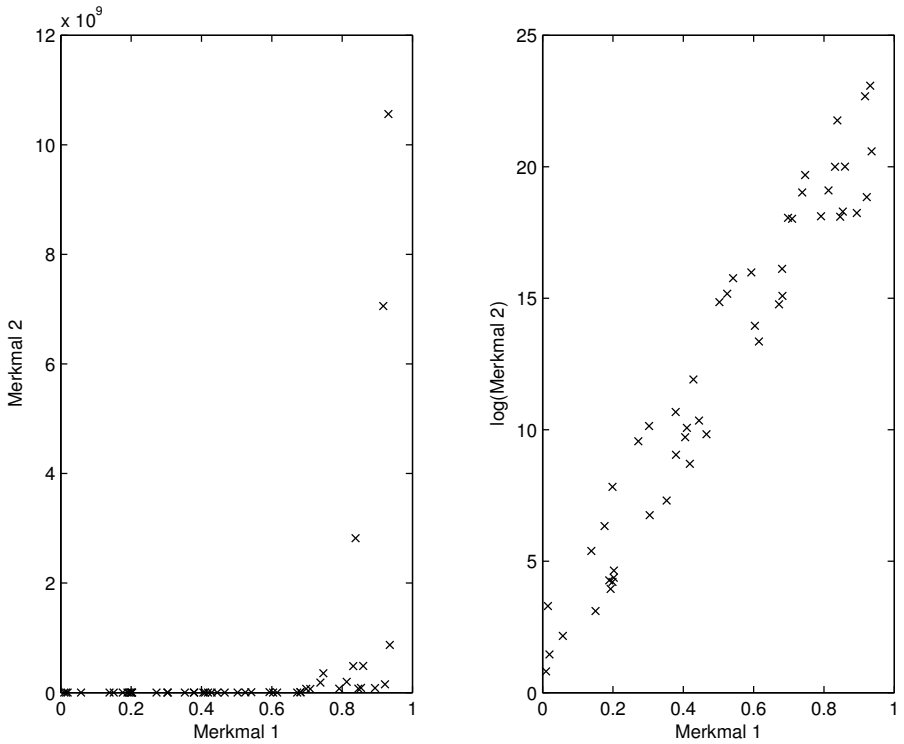

Abbildung 3.2: Scatterplots.

Abbildung 3.2 zeigt zwei Scatterplots derselben Stichprobe: der linke Plot verwendet lineare Skalierung (also einen "Zoom" in die Daten), im rechten Plot wurden die Werte von Merkmal 2 (Y) logarithmiert. Durch diesen Skalenwechsel wird ein linearer stochastischer Zusammenhang der Form

$$\log(Y) = a \cdot X + b \tag{3.1}$$

mit geeigneten Parametern a und b deutlich.

Hier ist (3.1) ein Modell für den vermuteten Zusammenhang. Konkret handelt es sich um das "lineare Modell".

3.3 Korrelation - Stärke und Richtung des linearen Zusammenhangs

Wir definieren die empirische **Kovarianz**

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n-1}\sum_{i=1}^{n}x_i y_i - \frac{n}{n-1}\bar{x}\bar{y}$$

Die rechte Formel erlaubt die Berechnung aus aufsummierten Größen und eignet sich daher auch für Datenbestände bei denen laufend Daten ergänzt werden.

Um nun den linearen Zusammenhang der Merkmale X und Y zu quantifizieren verwendet man den **Korrelationskoeffizienten** (nach Pearson):

$$r_{xy} = \frac{s_{xy}}{s_x \cdot s_y} = \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sqrt{\left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2\right)\left(\sum_{i=1}^{n} y_i^2 - n\bar{y}^2\right)}},$$

wobei die rechte Formel wieder die "online" Variante ist. Es gilt: $-1 \leq r_{xy} \leq 1$, negative Werte bedeuten, dass größere Werte des ersten Merkmales mit kleineren Werten des zweiten Merkmales korrespondieren. Das Quadrat des Korrelationskoeffizienten r_{xy}^2 nennt man **empirisches Bestimmtheitsmaß**, $0 \leq r_{xy}^2 \leq 1$.

Achtung: Die Maße r_{xy} und s_{xy} geben nur Auskunft über lineare Zusammenhänge. Ein Skalenwechsel bei einem der Merkmale kann daher den Grad der Korrelation erheblich beeinflussen. In Abbildung 3.2 ergibt sich links der Wert $r_{xy} = 0.377$ und rechts $r_{xy} = 0.972$. Abbildung 3.3 zeigt 4 sehr unterschiedliche Datensätze mit $r_{xy} \approx 0.7$. Eine positive Korrelation impliziert nicht unbedingt ein lineares Modell als beste Erklärung für die beobachteten Daten!

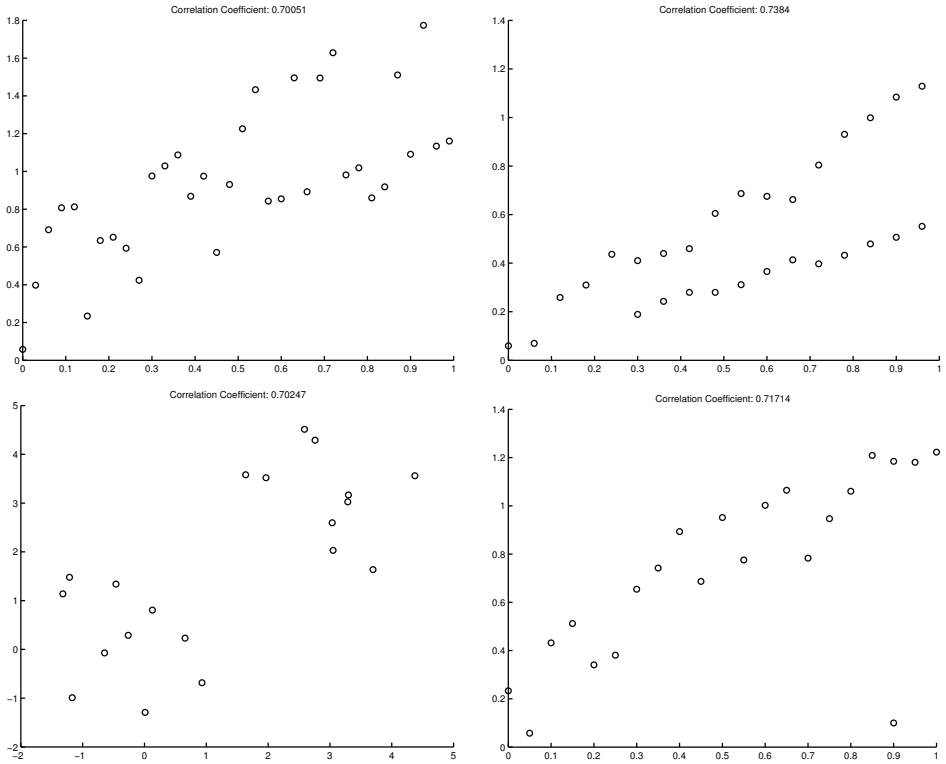

Abbildung 3.3: Scatterplots und Korrelationskoeffizient zu 4 Datensätzen

Berechnung aus Kontingenztabellen: Die Werte s_x, s_y, $\bar{x}$ und $\bar{y}$ werden mit den aus Kapitel 1 bekannten

Formeln aus den Randhäufigkeiten ermittelt. Weiters berechnet man

$$s_{xy} = \frac{n}{n-1} \sum_{i,j} h_{ij}(a_i - \bar{x}) \cdot (b_j - \bar{y})$$

Analog werden bei Klassen statt a_i und b_i die entsprechenden Klassenmittel oder -schwerpunkte der Klasseneinteilung des jeweiligen Merkmales verwendet.

3.4 Regression: Modellanpassung

Liegt bei einem Datensatz ein hohes Bestimmtheitsmaß vor ($r_{xy}^2 \geq 0.5$), und legt der Scatterplot einen linearen Zusammenhang nahe, so kann man mit dem Verfahren der linearen Regression die optimalen Parameter a und b des Modells $y = a \cdot x + b$ bestimmen. Hier nennt man y die abhängige, und x die unabhängige Variable. Optimal bedeutet dabei, dass die Summe der Fehlerquadrate minimal wird: Es sei $\hat{y}_i = a \cdot x_i + b$ die Vorhersage des Modells für den Wert y_i. Man nennt $r_i = y_i - \hat{y}_i$, also die Differenz zwischem beobachtetem und durch das Modell vorhergesagtem Wert, das i-te Residuum (a und b sind hier noch unbekannt!). Sei dann $err_{tot} = \sum_{i=1}^{n} r_i^2$ die Fehlerfunktion. Mittels Extremwertrechnung (partielle Ableitung der Fehlerfunktion nach a und b) erhält man die optimalen Parameter a und b (die Rechnung führen wir in der LVA aus):

$$a = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - \bar{x}^2} = \frac{s_{xy}}{s_x^2}$$

Die Gerade $y = a \cdot x + b$ heißt **erste Regressionsgerade**. Merkregel: mindestens 5 Datenpunkte bei linearer Regression! Analog kann man auch über die horizontalen Abstände minimieren und erhält die **zweite Regressionsgerade** $x = a^* y + b^*$ mit

$$a^* := \frac{s_{xy}}{s_y^2} \qquad b^* = \bar{x} - a^* \bar{y}$$

Die erste und zweite Regressionsgerade sind im allgemeinen verschieden. Je besser die Punkte durch das lineare Modell beschrieben werden, desto näher liegen die beiden Geraden aneinander. Als Beispiel betrachten wir folgende Daten:

x_i	1	3	4	5	6
y_i	1.4	2.5	3.6	5.5	5.4

Hier erhält man $a = 0.8973$, $b = 0.2703$ und $a^* = 1.0320$, $b^* = 0.0022$, beide Modelle sind in Abbildung 3.4 eingezeichnet. Der Quotient der beiden Steigungen k_1, k_2 (also das Produkt der Parameter a und a^*) von erster und zweiter Regressionsgerade ergibt das Quadrat des Korrelationskoeffizienten:

$$\frac{k_1}{k_2} = a * a^* = \frac{s_{xy}^2}{s_x^2 s_y^2} = r_{xy}^2$$

Dieses Bestimmtheitsmaß erhält man auch wie folgt: Es sei

$$\hat{s}^2 = \frac{1}{n-2} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

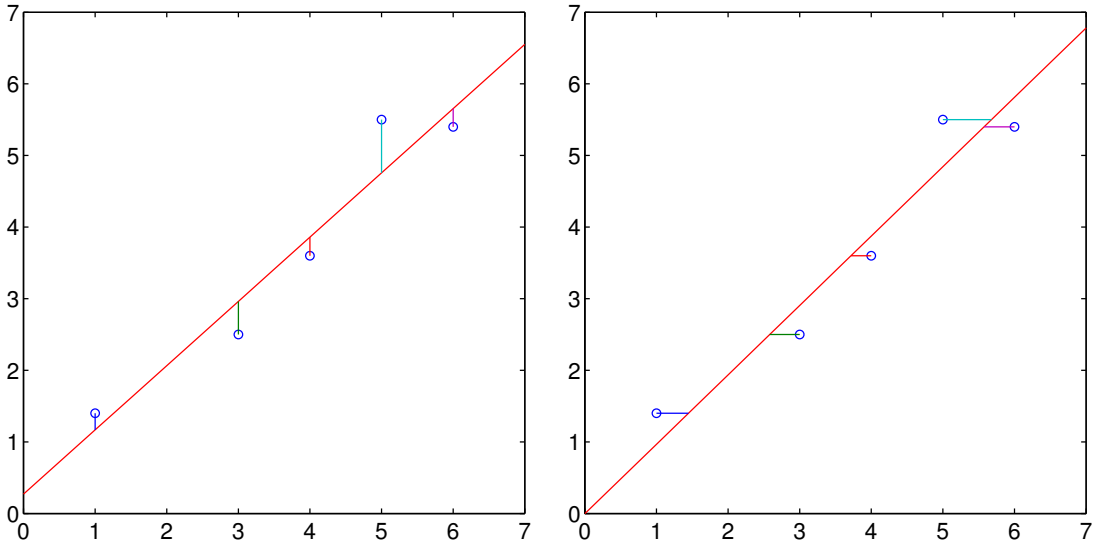

Abbildung 3.4: Erste und zweite Regressionsgerade

die **Reststreuung** der Werte um die Modellvorhersagen. Dann gilt:

$$r_{xy}^2 = 1 - \frac{n-2}{n-1} \cdot \frac{\hat{s}^2}{s_y^2}$$

In dieser Form kann das Bestimmtheitsmaß verallgemeinert werden, siehe weiter unten.

3.4.1 Umsetzung mit Python

Das folgende Listing zeigt die Umsetzung mit Python anhand eines Zufallsdatensatzes, Abbildung 3.5 zeigt den zugehörigen Output.

```
import numpy as np
import matplotlib.pyplot as plt
np.random.seed(42)
x = np.random.rand(20)*30
y = 2*x-3+np.random.randn(len(x))*6

curve_model = np.poly1d(np.polyfit(x, y, 1))

curve_fitting_line = np.linspace(1, 30, 1000)

plt.scatter(x, y)
plt.plot(curve_fitting_line, curve_model(curve_fitting_line))
plt.show()
```

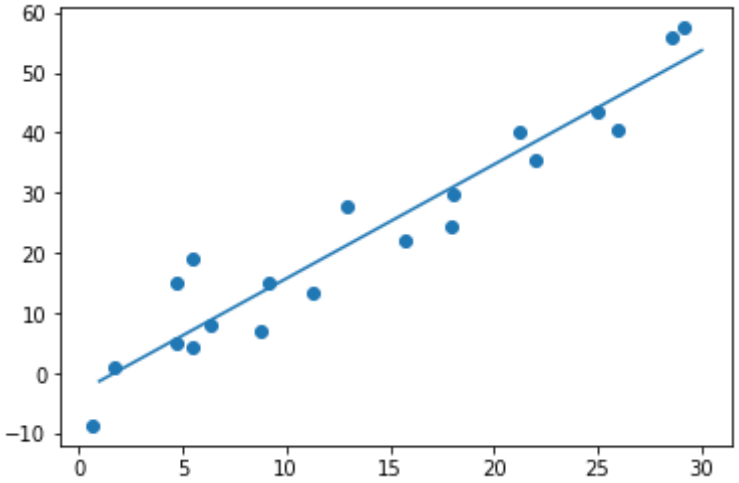

Abbildung 3.5: Lineare Regression mit Gerade (Trendlinie).

3.4.2 Weitere Modelle für lineare Regression

Lineare Regression kann auch für kompliziertere Modelle als das lineare Modell $y = a \cdot x + b$ verwendet werden. Liegen k "Bausteinfunktionen" f_i, $1 \leq i \leq k$ vor, und werden diese durch Linearkombination zu einem Regressionsmodell

$$y = f(x) = \delta_1 \cdot f_1(x) + \ldots + \delta_k \cdot f_k(x)$$

kombiniert, so können die unbekannten Parameter $\delta_1, \ldots, \delta_k$ wieder mit dem Verfahren der linearen Regression bestimmt werden. Aufgrund der Komplexität der Formeln werden diese hier nicht angegeben, stattdessen wird in der Übung die Berechnung mithilfe von mathematischer Software besprochen. Beispiele:

$$y = \delta_1 \cdot x^2 + \delta_2 \cdot x + \delta_3 \qquad y = \delta_1 \cdot \sin(x) + \delta_2 \cdot \cos(x) + \delta_3$$

Das Bestimmtheitsmaß berechnet sich aus den Modellvorhersagen $\hat{y}_i = f(x_i)$ wieder durch:

$$r_{xy}^2 = 1 - \frac{n-k}{n-1} \cdot \frac{\hat{s}^2}{s_y^2} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Dieses Maß berücksichtigt allerdings nicht den Effekt, dass durch mehrere Modellparameter (höheres k) natürlich eine bessere Anpassung des Modells an Daten möglich ist. Das sogenannte korrigierte Bestimmtheitsmaß trägt dem Rechnung und schätzt die Reststreuung erwartungstreu:

$$\bar{r}_{xy}^2 = 1 - \frac{\hat{s}^2}{s_y^2} = 1 - \frac{\frac{1}{n-k} \sum_{i=1}^n (y_i - \hat{y}_i)^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

Der Wert von $\bar{r}_{xy}^2$ steigt mit besserem Fit des Modells an die Daten bei Erhöhung der Parameterzahl k nur dann an (gegen seinen maximalen Wert von 1), wenn die niedrigeren Residuen nicht durch den Faktor $\frac{n-1}{n-k}$ wettgemacht werden. Generell sollten die nach Modellanpassung erhaltenen Residuen in einem Scatterplot oder mittels Q-Q-Plot auf Auffälligkeiten und Normalverteilung untersucht werden.

Die empfohlene Vorgangsweise wird anhand einer Regression mit einem Polynom vom Grad $n = k - 1$

(z.B: ist ein Polynom 1. Grades eine Gerade und hat 2 Parameter) illustriert. Dazu kann folgender Code benutzt werden:

```
import numpy as np
import matplotlib.pyplot as plt
from ipywidgets import interactive
def f(n):
        x = [1,2,3,4,5,6,7,8,9,10,11,12,15,17,22,23,25,30]
        y = [100,90,80,60,60,55,60,65,70,70,75,76,78,79,90,99,99,100]

        curve_model = np.poly1d(np.polyfit(x, y, n))

        residuals = curve_model(x) - y
        n_parameters = n+1
        n_data = len(y)
        s_hat_sq = (1/(n_data-n_parameters)) * np.dot(residuals,residuals)
        sy_hat_sq = (1/(n_data-1)) * np.dot(y-np.mean(y),y-np.mean(y))
        corr_RS = 1 - (s_hat_sq/sy_hat_sq)

        curve_fitting_line = np.linspace(1, 30, 1000)

        plt.scatter(x, y)
        plt.plot(curve_fitting_line, curve_model(curve_fitting_line))
        plt.text(10,100,'corrected R^2 = %f' % corr_RS)
        plt.show()


interactive_plot = interactive(f,n=(1,10))
interactive_plot
```

Ausgewählte Ergebnisse sind in Abbildung 3.6 zu sehen. Das korrigierte Bestimmtheitsmaß steigt zunächst deutlich an, mehr als Grad 4 (also 5 Parameter) bringen jedoch kaum mehr eine Erhöhung. Im Gegenteil, das Modell scheint im rechten Bereich (höchste Werte von x) unnötig zu schwingen.

Im Allgemeinem wird man daher einem einfacheren Modell (kleineres k) den Vorzug geben, solange das Bestimmtheitsmaß nicht deutlich schlechter ausfällt. Bei der Wahl eines geeigneten Modells helfen Vorinformationen über die Daten (Art und Weise der Entstehung, Art der Messung, ...) und eine genaue Analyse des Scatterplots beziehungsweise der Residuen: sind die Residuen normalverteilt und unabhängig (also an allen Stellen des Plots sowohl negativ als auch positiv und von der Größenordnung her gleich), hat man eine gute Lösung gefunden. Das Polynom vom Grad 1 in der linken Abbildung erfüllt diese Anforderung nicht, die Residuen sind für sehr kleine und sehr große x nur positiv und für mittlere Werte von x nur negativ.

Eine genauere Rechtfertigung der geschilderten Vorgangsweise ergibt sich aus den Modellannahmen der Regression, welche (u.a.) genau diese Verteilung für die Reststreuung verlangen.

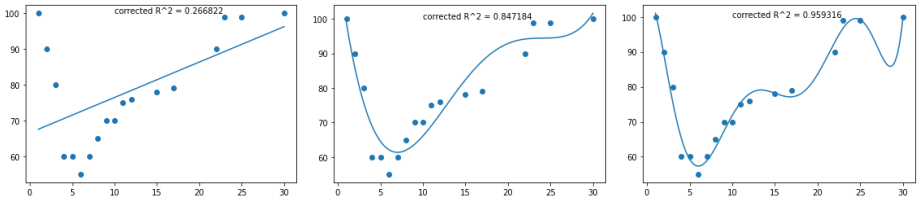

Abbildung 3.6: Regressionsrechnung mit Polynomen der Grade 1, 4 und 7.

3.4.3 Nichtlineare Regression

Manchmal ist der Zusammenhang der Merkmale nicht gut durch ein lineares Modell beschreibbar. Soll beispielsweise aus periodischen Daten eine Frequenz geschätzt werden, muß ein **nicht-lineares Modell** der Form $y = \delta_1 \cdot \sin(\delta_2 \cdot x + \delta_3)$ mittels **nicht-linearer Regression** angepasst werden. Abbildung 3.7 zeigt ein Beispiel zu diesem Modell. Achtung: Modelle der Form $y = \exp(a \cdot x + b)$ sollten mittels Skalenwechsel (logarithmieren der y-Werte) in lineare Modelle umgewandelt werden.

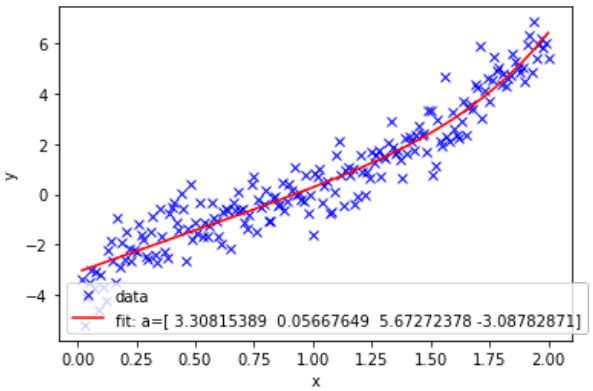

Abbildung 3.7: Nicht-lineare Regression mit Sinusfunktion

Im Gegensatz zu linearer Regression ist nichtlineare Regression ein hochdimensionales Optimierungsproblem mit nicht eindeutig bestimmter Lösung. Die Algorithmen können u.U. gar nicht oder in ein lokales Minimum der Kostenfunktion (Summe der Residuenquadrate) konvergieren und sind von der Wahl geeigneter Startwerte in Form einer Schätzung der gesuchten Modellparameter abhängig. In Python könnte eine solche Regression in etwa wie folgt realisiert werden:

```
import numpy as np
from scipy.optimize import curve_fit
import matplotlib.pyplot as plt
from ipywidgets import interactive


filename = 'mydata.txt'
data = np.loadtxt(filename, delimiter='\t',
                  skiprows=1,
                  dtype=str).astype(np.float32)
x = data[:,0]
y = data[:,1]

def func(x, a1, a2, a3, a4): # example for nonlinear regression
        return a1 * x + a2 * np.power(x,a3) + a4
```

```
popt, pcov = curve_fit(func, x, y, p0=[1,1,1,1])

plt.plot(x, y, 'bx', label='data')
plt.plot(x, func(x, *popt), 'r-',
label='fit: a=%s' % str(popt))
plt.xlabel('x')
plt.ylabel('y')
plt.legend()
plt.show()
```

Der Befehl `curve_fit` benötigt neben dem Modell `func` und den Daten x und y auch den Startwert `p0`. Dieser Vektor hat genau so viele Komponenten wie das Modell Parameter hat.

3.4.4 Ausblick: Mehrdimensionale Regression

Liegen höherdimensionale Daten vor, so empfiehlt sich zunächst die Analyse der Matrix aller paarweisen Korrelationskoeffizienten: sind zum Beispiel Datenpunkte der Form (x_i, y_i, z_i, w_i) gegeben, so berechnet man zunächst die 4×4 Matrix

$$R = (r_{ij})_{i,j \in \{x,y,z,w\}} = \begin{pmatrix} r_{xx} & r_{xy} & r_{xz} & r_{xw} \\ r_{yx} & r_{yy} & r_{yz} & r_{yw} \\ r_{zx} & r_{zy} & r_{zz} & r_{zw} \\ r_{wx} & r_{wy} & r_{wz} & r_{ww} \end{pmatrix}$$

Klarerweise ergeben sich in der Diagonale lauter Einsen (jeder Wert korreliert mit sich selbst). Aufgrund der Symmetrie des Korrelationskoeffizienten ist auch die Matrix R symmetrisch. Besonders große oder kleine Werte (Absolutwert größer 0.7) geben einen Hinweis auf mögliche lineare Korrelation der jeweiligen Merkmale. Ein Scatterplot der entsprechenden Merkmale kann diesen Verdacht eventuell weiter erhärten.

Für die mehrdimensionale Regression legt man zunächst eine abhängige Variable fest, zum Beispiel w. Man definiert dann ein Modell der Form $w = f(x, y, z)$ das den Zusammenhang beschreibt. Dieses Modell kann wieder k unbekannte Parameter enthalten die aus den Daten so geschätzt werden sollen, daß die Summe der Fehlerquadrate

$$err_{tot} = \sum_{i=1}^{n} (w_i - \hat{w}_i)^2$$

für die Modellvorhersagen $\hat{w}_i = f(x_i, y_i, z_i)$ minimal wird. Das Verfahren dazu nennt man **mehrdimensionale Regression** und unterscheidet wie oben lineare und nicht-lineare Regression je nachdem ob die Parameter außerhalb oder innerhalb der Bausteinfunktionen stehen. Beispiele:

$$\begin{aligned} w &= \delta_1 \cdot x + \delta_2 \cdot y + \delta_3 \cdot z + \delta 4 && \text{(linear)} \\ w &= \sin(\delta_1 \cdot x + \delta_2 \cdot y + \delta_3 \cdot z + \delta 4) && \text{(nicht-linear)} \end{aligned}$$

Ein Beispiel für 3-dimensionale Daten ist in Abbildung 3.8 zu sehen.

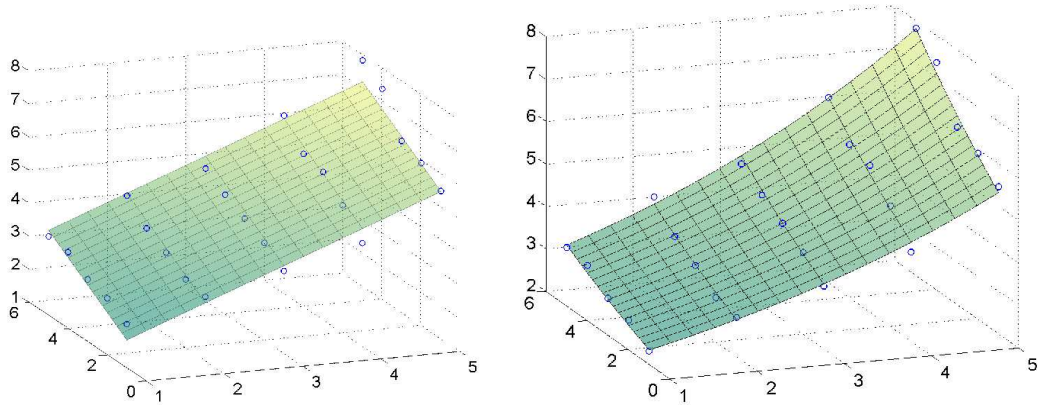

Abbildung 3.8: Regression mit Modellen $z = \delta_1 \cdot x + \delta_2 \cdot y$ und $z = \exp(\delta_1 \cdot x + \delta_2 \cdot y)$

Kapitel 4

Parameterschätzung und Konfidenzintervalle

4.1 Parameterschätzung

In der Schätztheorie versucht man, unbekannte Parameter (etwa p bei einer Bernoulliverteilung oder μ bei einer Normalverteilung) eines Modelles aus Daten zu schätzen. Die Grundidee dabei ist: Das Modell für die Daten wird bis auf den Parameter festgelegt - etwa: die Daten folgen einer Bernoulliverteilung mit Parameter p, d.h., Erfolg tritt mit der noch unbekannten Wahrscheinlichkeit p ein. Nun denkt man sich n Kopien des Modells, $X_1, \ldots, X_n$, mit der zusätzlichen Eigenschaft, dass diese Kopien unabhängig voneinander sind. Dieser Satz von n Zufallsvariablen - man spricht von unabhängigen und identisch verteilten Variablen und schreibt dafür im Englischen independent, identically distributed (i.i.d.) - beschreibt also die n-fache Wiederholung eines Experimentes in der Art, dass jedes Experiment zu gleichen Bedingungen und jeweils unabhängig von den anderen ausgeführt wird. Beispiel: n-mal den Reissnagel werfen, $X_i = 1$ wenn im i'te Versuch der Reissnagel auf den Kopf fällt, und $X_i = 0$ sonst. Wird das Experiment konkret durchgeführt, so erhält man n Zahlenwerte, die man mit $x_1, \ldots, x_n$ bezeichnet, also eine Stichprobe.

In der Schätztheorie untersucht man nun Funktionen der n Zufallsvariablen $X_1, \ldots, X_n$, die den gesuchten Wert geeignet schätzen. Wir lernen im Folgenden Schätzer für die wichtigesten Parameter von diskreten und stetigen Verteilungen sowie für Mittelwert und Varianz einer beliebigen Verteilung kennen.

4.1.1 Schätzer für die Erfolgswahrscheinlichkeit $\hat{p}$

Gegeben sei ein Bernoulli-Experiment mit unbekannter Erfolgswahrscheinlichkeit p, welche aus n Beobachtungen des Experimentes geschätzt werden soll. Intuitiv wird man für diesen gesuchten **Parameter** p die relative Häufigkeit

$$\hat{p} = \frac{1}{n}\#\Big\{ \text{ Erfolge bei } n \text{ Experimenten } \Big\}$$

als Schätzwert verwenden. Formal wird die Serie von n Experimenten durch n unabhängige Kopien $X_1, \ldots, X_n$ einer Zufallsvariable X mit diskreter Dichte $X \sim B_p$ beschrieben. Also: $X_i \sim B_p$, X_i und

X_j sind unabhängig für $i \neq j$. Der **Schätzer** ist nun eine Funktion dieser n Zufallsvariablen und somit wieder eine **Zufallsvariable**

$$\hat{p} = \frac{1}{n} \sum_{i=1}^{n} X_i$$

(Zur Erinnerung: X_i hat den Wert 1 wenn Erfolg eintritt und sonst den Wert 0.)

Wird die Schätzung konkret ausgeführt, so werden die n Zufallsvariablen $X_1, \ldots, X_n$ durch n Realisierungen (konkrete Werte, Zahlen) $x_1, \ldots, x_n$ ersetzt und der Wert der Zufallsvariablen $\hat{p}$ für diese Realisierungen ausgerechnet (Dieser Wert wird dann ebenfalls Realisierung von $\hat{p}$ genannt und als Schätzung für p verwendet).

Der Schätzer $\hat{p}$ hat 2 wichtige Eigenschaften:

1. Erwartungstreue – "treffe im Mittel":

$$E[\hat{p}] = \frac{1}{n} E\left[\underbrace{\sum_{i=1}^{n} X_i}_{\sim B_{n,p}}\right] = \frac{1}{n} \cdot n \cdot p = p$$

2. Konsistenz – "Schätzgenauigkeit steigt mit der Versuchsanzahl":

$$V[\hat{p}] = \frac{1}{n^2} V\left[\underbrace{\sum_{i=1}^{n} X_i}_{\sim B_{n,p}}\right] = \frac{1}{n} \cdot p \cdot (1-p) \overset{n\to\infty}{\to} 0$$

Man nennt $\hat{p}$ einen **Punktschätzer** für den unbekannten Parameter p. Der wahre Wert p wird i.a. natürlich vom Schätzwert abweichen. Weiter unten wird daher statt der Punktschätzung ein Intervall konstruiert, dass den wahren Wert mit einer vorgegebenen Sicherheit enthält.

4.1.2 Allgemeiner Fall

Gegeben ist ein Experiment X und eine Verteilungsannahme $X \sim f_{X,\Theta}$ mit unbekanntem Parameter $\Theta \in \mathbb{R}^d$. Beispiel: $X \sim N(\mu, \sigma)$, also $\Theta = (\mu, \sigma) \in \mathbb{R}^2$.

Eine Funktion $\hat{\Theta} : \mathbb{R}^n \to \mathbb{R}^d$ heißt **Statistik** von $X_1, \ldots, X_n$ für den unbekannten Parameter Θ wenn die X_i paarweise unabhängige Kopien von X sind. Statistiken sind Zufallsvariable! Das Ziel ist es dabei, den Wert des (der) Parameter mittels $\hat{\Theta}$ zu schätzen, also im obigen Beispiel $(\hat{\mu}, \hat{\sigma}) = \hat{\Theta}(X_1, \ldots, X_n)$. Dabei werden die ZVen X_i durch konkrete Realisationen (Beobachtungen) $x_i \in \mathbb{R}$ ersetzt und die Funktion $\hat{\Theta}$ liefert aus diesen Daten den gewünschten Schätzwert. Zur besseren Unterscheidung werden die Schätzer der Parameter mit $\hat{}$ bezeichnet.

Gute Schätzer sind

1. "erwartungstreu": $E[\hat{\Theta}] = \Theta$
2. "konsistent": $V[\hat{\Theta}] \overset{n\to\infty}{\to} 0$ (eigentlich: Konvergenz in Wahrscheinlichkeit, siehe Fachliteratur)

4.1.3 Wichtige Schätzer für Parameter

Die folgenden Schätzer sind alle zumindest asymptotisch erwartungstreu und konsistent.

Verteilung	Schätzer	Kommentar
$B_p,\ B_{n,p}$	$\hat{p} = \frac{1}{n}\sum_{i=1}^{n} X_i$	X_i ... Indikator `numpy.mean(data)`
P_λ	$\hat{\lambda} = \frac{1}{n}\sum_{i=1}^{n} X_i$	X_i ... Anzahl Treffer im Zeitintervall bei i'tem Versuch `numpy.mean(data)`
G_p	$\hat{p} = \frac{1}{\frac{1}{n}\sum_{i=1}^{n} X_i}$	X_i ... Wartezeit (Versuche) auf Erfolg beim i'tem Versuch `1/numpy.mean(data)`

$N(\mu, \sigma^2)$	$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i$
	$\hat{\sigma} = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \hat{\mu})^2}$
		X_i ... Wert der i'ten Beobachtung
		`numpy.mean(data)`
		`numpy.std(data,ddof=1)`

E_λ	$\hat{\lambda} = \frac{1}{\frac{1}{n}\sum_{i=1}^{n} X_i}$	X_i ... Wartezeit auf i'te Beobachtung `1/numpy.mean(data)`

4.1.4 Wichtige Schätzer für Momente

Auch ohne genauere Verteilungsannahmen können Erwartungswert und Varianz eines Modells aus Beobachtungen geschätzt werden. Ist X eine ZV mit $E[X] = \mu$ und $V[X] = \sigma^2$ und sind $X_1,\ldots,X_n$ n unabhängige Kopien (Wiederholungen) dann gilt:

Wert	Schätzer	Kommentar
Erwartungswert $\mu = E[X]$	$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i$	Dieser Schätzer ist selbst asymptotisch normalverteilt (zentraler Grenzwertsatz): $\hat{\mu} \approx N(\mu, \frac{\sigma^2}{n})$ `mu_hat=numpy.mean(data)`
Varianz $\sigma^2 = V[X]$	$\hat{\sigma}^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \hat{\mu})^2$	Dieser Schätzer ist selbst asymptotisch chiquadratverteilt mit $n-1$ Freiheitsgraden: $\frac{n-1}{\sigma^2} \cdot \hat{\sigma^2} \approx \chi^2_{n-1}$ `sig_hat=numpy.var(data,ddof=1)`

Die in diesem Zusammenhang auftretende Statistik $\hat{T} = \sqrt{n}\frac{\hat{\mu}-\mu}{\sqrt{\hat{\sigma}^2}}$ ist asymptotisch Student-T verteilt

$\hat{T} \approx T_{n-1}$ mit $n-1$ Freiheitsgraden. Chiquadrat- und die Student-T-Verteilung sind stetige Verteilungen deren genaue Eigenschaften in der Fachliteratur nachgelesen werden können.

4.2 Konfidenzintervalle

Wie oben besprochen weicht eine Punktschätzung i.a. vom wahren Wert des gesuchten Parameters ab. Oft wird daher statt eines Punkschätzers die Angabe eines sogenannten **Konfidenzintervalls** (KI) bevorzugt. Wir greifen das Beispiel des Schätzers $\hat{p}$ für die Erfolgswahrscheinlichkeit in einem Bernoulli-Experiment wieder auf und geben uns zunächst die Irrtumswahrscheinlichkeit α, etwa $\alpha = 0.05$, vor.

Beispiel: Eine Exit-Poll ergab, dass von den 100 Befragten 55 für Partei A und 45 für Partei B gestimmt hatten. Die Erfolgswahrscheinlichkeit für A liegt also bei $\hat{p} = 55\%$ (Punktschätzung). In welchem Intervall liegt das wahre p mit 95%iger Wahrscheinlichkeit? Kann sich A schon als Sieger wähnen?

Ein $(1-\alpha)\cdot 100\%$-iges KI für den Parameter p gegeben die n Beobachtungen $X_1, \ldots, X_n$ ist ein Intervall $[p_u, p_o]$, das den wahren Wert p mit $(1-\alpha)\cdot 100\%$-iger Wahrscheinlichkeit enthält (unter der Annahme, dass die B_p-Verteilung für X zutrifft). Typische Werte für α sind 0.05 und 0.01, üblicherweise wird das Intervall symmetrisch um den Punktschätzer konstruiert, also $p_u = \hat{p} - l$ und $p_u = \hat{p} + l$ gesetzt. Nun soll l so bestimmt werden, dass die Irrtumswahrscheinlichkeit garantiert werden kann.

Wegen $n\hat{p} \sim B_{n,p}$ gilt für $l > 0$ und $p_u = \hat{p} - l$ und $p_o = \hat{p} + l$:

$$\begin{aligned} P[p \in [pu, po]] &= P[\hat{p} - l \le p \le \hat{p} + l] = P[p - l \le \hat{p} \le p + l] = \\ &= P[n(p-l) \le \underbrace{n \cdot \hat{p}}_{\sim B_{n,p}} \le n(p+l)] \approx \text{ (mittels Normalapprox.)} \\ &\approx 2 \cdot \Phi\left(\sqrt{\frac{n}{p(1-p)}} \cdot l\right) - 1 := 1 - \alpha \end{aligned}$$

Mittels der inversen Verteilungsfunktion Φ^{-1} (MATLAB: `norminv`) löst man diese Gleichung nach l auf, schätzt die unbekannte Größe $\sqrt{p \cdot (1-p)}$ durch $1/2$ ab (schlimmster Fall) und erhält:

$$l = \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \cdot \sqrt{\frac{p(1-p)}{n}} \le \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \cdot \frac{1}{2\sqrt{n}} =: l^*$$

Folglich enthält das KI

$$[\hat{p} - l^*, \hat{p} + l^*]$$

den Parameter p mit mindestens $(1-\alpha)\cdot 100\%$-iger Wahrscheinlichkeit. Ist wie in unserem Beispiel konkret $\alpha = 0.05$ und $n = 100$, so ergibt sich der Wert $l^* = \frac{0.98}{10} = 0.098$, der wahre Wert von p liegt also mit 95%iger Sicherheit im Bereich $[0.452, 0.648]$, der Erfolg von Partei A steht also noch auf sehr wackeligen Füßen.

Wir fassen also zusammen: Liegen n ua. Realisierungen eines Bernoulli Experimentes vor, so ist das Intervall

$$\left[\hat{p} - \frac{k}{2\sqrt{n}}, \hat{p} + \frac{k}{2\sqrt{n}}\right]$$

ist ein $(1-\alpha)\cdot 100\%$ KI für den wahren Wert der Erfolgswahrscheinlichkeit p, wenn $k = \Phi^{-1}(1-\frac{\alpha}{2})$.

In Python kann man das KI wie folgt berechnen:

```
alpha=0.05 # 95% KI
# exit poll Daten
n = 100  # Groesse der iid Stichprobe
p_hat = 0.55
k = stats.norm.ppf(1-alpha/2)
l = k/(2*np.sqrt(n))
print('KI mit %f %% Konfidenz Niveau: [ %f,%f ]'
   % ((1-alpha)*100,p_hat-l,p_hat+l))
```

Umgekehrt kann mit diesem KI eine Studienplanung gerechnet werden. Sind gewünschte Sicherheit (zum Beispiel 95%, also $\alpha = 0.05$) und Schätzgenauigkeit (zum Beispiel ±3%, also $l = 0.03$) vorgegeben, löst man das KI nach n auf und erhält:

$$n = \left(\frac{k}{2\cdot l}\right)^2 \approx 1067.$$

Es müssen also mehr als 1000 Daten vorliegen, um mittels der relativen Häufigkeit den Wert entsprechend gut schätzen zu können.

Mit den in Abschnitt 4.1.4 angegebenen Verteilungen lassen sich weiters die folgenden KIs für den nicht-parametrischen Schätzer für den Erwartungswert angeben (ohne zusätzliche Verteilungsannahme, dafür aber nur näherungsweise für große n):

- Liegen n ua. Realisierungen eines beliebigen Experimentes vor, so gilt für große n näherungsweise: Das Interval
$$\left[\hat{\mu} - \frac{k\cdot\sigma}{\sqrt{n}}, \hat{\mu} + \frac{k\cdot\sigma}{\sqrt{n}}\right]$$
ist ein $(1-\alpha)\cdot 100\%$ KI für den Erwartungswert μ wenn $k = \Phi^{-1}(1-\frac{\alpha}{2})$ und σ^2 die bekannte Varianz des Experimentes ist.
Python: `k = scipy.stats.norm.ppf(1-alpha/2)`.
Ist das Experiment im Speziellen normalverteilt, so gilt dieses KI für beliebige n exakt.

- Weiters gilt dann: Das Interval
$$\left[\hat{\mu} - \frac{k\cdot\hat{\sigma}}{\sqrt{n}}, \hat{\mu} + \frac{k\cdot\hat{\sigma}}{\sqrt{n}}\right]$$
ist ein $(1-\alpha)\cdot 100\%$ KI für den Erwartungswert μ wenn $k = T_{n-1}^{-1}(1-\frac{\alpha}{2})$ und die unbekannte Standardaabweichung ebenfalls aus den Daten als $\hat{\sigma}$ geschätzt werden muß.
Python: `k = scipy.stats.t.ppf(1-alpha/2,n-1)`.
Wie oben gilt auch hier: ist das Experiment normalverteilt, so gilt dieses KI für beliebige n exakt.

Das folgende Beispiel illustriert die Verwendung dieser KIs: Ein unterirdisch verlegtes 5 km langes Datenkabel ist gerissen. Mittels eines Messinstrumentes, das die Signalreflektion an der Rissstelle nutzt, werden vom einen Ende des Kabels aus 5 Messungen getätigt, die folgende Positionen der Rissstelle ergeben:

$$2124, 2119, 2080, 2122, 2070 \text{ (Meter vom Kabelende entfernt)}$$

Eine Baufirma soll nun mit Aushubarbeiten beauftragt werden, die Kosten dafür sollen auf der Basis einer 90% Sicherheit, die Rissstelle im Bereich des Aushubs zu finden, geschätzt werden. Die Baufirma muss also einen Bereich $[l_u, l_o]$ finden, indem die Rissstelle mit 90% Sicherheit liegt. Danach kann sie die Kosten für diesen Bereich abschätzen.

Wir betrachten 3 Varianten:
a) Das Messgerät liefert einen Wert X, der als normalverteilt mit Streuung 30 Meter und erwartungstreu angenommen wird. Der wahre Wert ist also mit einem normalverteilten Messfehler mit Mittelwert Null und Varianz 900 überlagert. Die Schätzung für die Position der Rissstelle ergibt sich gemäß der Tabelle in Abschnitt 4.1.3 als Mittelwert

$$\hat{\mu} = \frac{2124 + 2119 + 2080 + 2122 + 2070}{5} = 2103.$$

Da die Varianz bekannt ist, berechnen wir mit $\alpha = 0.1$ den Wert $k = \Phi^{-1}(1 - \frac{\alpha}{2}) = \Phi^{-1}(1 - \frac{0.1}{2}) = 1.6449$ und erhalten $\frac{k \cdot 30}{\sqrt{5}} = 22.0680$. Das KI $[2080.9, 2125.1]$ (Meter) ist also ein Bereich in dem die Rissstelle mit der gewünschten Sicherheit liegt. Da der Messfehler und somit die Messung selbst normalverteilt sind, ist dieses Ergebnis exakt.

b) Wie a) nur ist nun die Streuung des Messfehlers unbekannt (man stelle sich vor, diese Angabe ist auf dem Messgerät nicht vermerkt). Wir schätzen also neben dem Mittelwert (wie oben $\hat{\mu} = 2103$) zunächst aus den Daten die empirische Varianz:

$$\hat{\sigma}^2 = \frac{(2124 - 2103)^2 + \cdots + (2070 - 2103)^2}{4} = 669,$$

und setzen $k = T_{n-1}^{-1}(1-\frac{\alpha}{2}) = T_4^{-1}(1-\frac{0.1}{2}) = 2.1318$. Somit ist $\frac{k \cdot 25.86}{\sqrt{5}} = 24.6595$ und das KI $[2078.3, 2127.7]$ (Meter) ist ein Bereich in dem die Rissstelle mit der gewünschten Sicherheit liegt. Da der Messfehler und somit die Messung selbst normalverteilt sind, ist dieses Ergebnis wieder exakt. Weil wir weniger Vorinformation haben (unbekannte Streuung) muß ein etwas längerer Bereich aufgegraben werden um dieselbe Sicherheit zu erlangen.

c) Wie b) nur wird der Messfehler nicht mehr als normalverteilt vorausgesetzt. Die Verteilung der Messung ist damit unbekannt und das Ergebnis aus b) gilt nicht mehr exakt sondern nur näherungsweise für große n. In der Praxis wird man daher zumindest etwa 25 statt nur 5 Messungen machen. Je ähnlicher die Verteilung der Messung einer Normalverteilung ist, desto genauer stimmt das berechnete Konfidenzintervall auch bei kleinen n. Über die Ungenauigkeit können jedoch mit unseren Mitteln keine numerischen Aussagen gemacht werden, $n = 25$ ist ein Erfahrungswert.

Kapitel 5

Ausblick: Einführung in die schließende Statistik

Die beschreibende Statistik hilft uns, erhobene Daten in übersichtlicher Weise darzustellen, gibt aber noch keinen Rahmen vor, der es erlauben würde, aus den Daten Schlussfolgerungen zu ziehen. Dazu betrachten wir folgendes Beispiel: Eine Münze wird 100 mal geworfen, 62 mal ergibt sich "Kopf", in den restlichen 38 Fällen "Zahl". Die relative Häufigkeit von "Kopf" ist also 0.62. Ist die Münze fair?

Um diese Frage beantworten zu können, muss zunächst die stochastische Modellbildung (Wahrscheinlichkeitsrechnung) benutzt werden, um ein Modell für die faire Münze zu erstellen. Danach kann die obige Frage reduziert werden auf die Frage, in wie weit Beobachtung und Modell einander entsprechen. Wir werden sehen, dass die schließende Statistik (im Speziellen hier die Testtheorie) die Frage auch nur mit einer gewissen Fehlerwahrscheinlichkeit beantworten kann - schließlich ist das erhaltene Resultat ja auch bei einer fairen Münze durchaus **möglich wenn auch selten**.

5.1 Formulierung von Hypothesen

Möchte man eine Frage aufgrund von beobachteten Daten entscheiden, so muß also zunächst ein (stochastisches) Modell erstellt werden, durch welches die Frage beschrieben wird. In unserem Fall ist das ein Modell für n-maliges Werfen einer fairen Münze: Der Grundraum ergibt sich als $\Omega = \{K, Z\}^n$, die Zufallsvariable X welche die Anzahl der "Kopf"-Resultate unter den n Würfen beschreibt ist

$$X(\omega^1, \ldots, \omega^n) = \#\{1 \leq i \leq n \ : \ \omega^i = K\},$$

hat den Wertebereich $\{0, \ldots, n\}$ (62 ist bei $n = 100$ also ein mögliches Ergebnis) und ist binomialverteilt mit Parametern $n = 100$ und $p = 1/2$, $X \sim B_{100,1/2}$.

Wir formulieren nun die Frage "Ist die Münze fair" in zwei Hypothesen um:

H_0**:** Die **Null-Hypothese** ist, dass das Modell der fairen Münze zutrifft, dass also die 62 beobachteten "Kopf"-Resultate aus einem Versuch stammen, der durch X beschrieben wird.

H_1**:** Die **Alternativ-Hypothese** ist, dass H_0 nicht zutrifft.

Beim statistischen Testen wird nun wie folgt vorgegangen: Zunächst gilt - wie bei Gericht - die Annahme: "Im Zweifel für den Angeklagten", mit anderen Worten: H_0 wird solange als richtig angenommen, bis sie aufgrund starker Indizien (Beobachtungen) zugunsten von H_1 verworfen werden muss.

Analysieren wir die Hypothesen noch etwas genauer: Untersucht werden soll ja nur die Frage, ob die Münze fair ist, nicht zum Beispiel die Frage, ob außer "Kopf" und "Zahl" noch weitere Möglichkeiten in Betracht kommen. Anders formuliert reduzieren sich die **Hypothesen** dehr auf bestimmte **Werte für den Parameter** p der Verteilung von X: Die Beobachtung wird immer durch ein $X \sim B_{100,p}$ beschrieben, wobei aber

H_0**:** $p = 1/2 := p_0$

H_1**:** $p \neq 1/2$

Diese Art von statistischen Tests nennt man auch parametrische Tests. Nicht-parametrische Tests gibt es etwa für den Erwartungswert einer Zufallsvariable mit unbekannter Verteilung. Man nennt solche Tests auch verteilungsfrei.

5.2 Entscheidungsregel und Bezeichnungen

Nun zu den "Indizien": Im vorliegenden Fall liegt es auf der Hand, eine **Entscheidungsregel** in Abhängigkeit der relativen Häufigkeit $\hat{p} = 0.62$ zu definieren. Grundidee ist: Ist die Wahrscheinlichkeit einer Abweichung um mehr als c, $P[|\hat{p} - p_0| \geq c]$ sehr klein, ist also mit anderen Worten H_0 eine sehr schlechte "Erklärung" der Beobachtung, so wird H_0 abgelehnt werden. Sehr gering bedeutet in der wissenschaftlichen Praxis weniger als $\alpha = 1\%$, für kritische Untersuchungen wird oft auch 0.1% oder 0.01% gefordert. In anderen Zusammenhängen reichen oft geringer Sicherheiten, etwa ein Signifikanzniveau von 5%.

Bevor wir diesen Wert c berechnen noch ein paar Bezeichnungen:

- Man nennt α *Signifikanzniveau* des statistischen Tests.
- Das Ergebnis wird im Falle der Akzeptanz von H_0 beschrieben als "Der statistische Test hat H_0 auf dem Signifikanzniveau von 5% nicht abgelehnt", kurz wird dafür auch $\rightsquigarrow H_0$ geschrieben. Für den Fall der Ablehnung schreibt man: "Der statistische Test lehnt H_0 auf dem 5%-igen Signifikanzniveau zugunsten von H_1 ab", kurz $\rightsquigarrow H_1$ oder $\not\rightsquigarrow H_0$ geschrieben.
- Die Größe $\hat{p}$ - also der aus den Daten berechnete Wert anhand dessen eine Entscheidung getroffen werden soll - nennt man *Teststatistik*. Die Normierung kann unterschiedlich sein, für unseren Anwendungsfall könnte (und wird in der Praxis) etwa auch die Größe $z = \sqrt{\frac{n}{p_0 \cdot (1-p_0)}}(\hat{p} - p_0)$ verwendet. Für dieses Beispiel bleiben wir zunächst aber bei $\hat{p}$.
- Die Menge jener Werte von $\hat{p}$ die unter H_0 nur mit der (sehr geringen) Wahrscheinlichkeit α auftreten, in unserem Fall also die Werte mit $|\hat{p} - p_0| \geq c$, nennt man *kritischen Bereich*.

- Die *Entscheidungsregel* ist: $\rightsquigarrow H_0$ wenn $|\hat{p} - p_0| < c$ und $\rightsquigarrow H_1$ wenn $|\hat{p} - p_0| \geq c$. Mit dieser Regel wird garantiert, dass der Fehler 1. Art (ich lehne H_0 ab, obwohl sie zutrifft) in höchstens $\alpha \cdot 100\%$ der Fälle auftritt. Der Fehler 2. Art (ich akzeptiere H_0, obwohl sie falsch ist), hingegen bleibt unkontrolliert.

Wir suchen also zu gegebenem α die Größe c mit

$$P[|\hat{p} - p_0| \geq c] = \alpha$$

Durch Einsetzen der Binomialverteilung ($p_0 = q_0 = 1/2$ aus H_0) und Normalapproximation ergibt sich:

$$\begin{aligned}
\alpha = P\left[|\hat{p} - p_0| \geq c\right] &= P\left[|X - n \cdot p_0| \geq c \cdot n\right] = \\
&= 1 - P\left[-c \cdot n \leq X - n \cdot p_0 \leq c \cdot n\right] = \\
&= 1 - P\left[-\frac{c \cdot n}{\sqrt{n \cdot p_0 \cdot q_0}} \leq \frac{X - n \cdot p_0}{\sqrt{n \cdot p_0 \cdot q_0}} \leq \frac{c \cdot n}{\sqrt{n \cdot p_0 \cdot q_0}}\right] = \\
&= 1 - P\left[-c\sqrt{\frac{n}{p_0 \cdot q_0}} \leq \frac{X - n \cdot p_0}{\sqrt{n \cdot p_0 \cdot q_0}} \leq c\sqrt{\frac{n}{p_0 \cdot q_0}}\right] \approx \\
&\approx 1 - \left(2\Phi\left(c\sqrt{\frac{n}{p_0 \cdot q_0}}\right) - 1\right) = 2 - 2\Phi\left(c\sqrt{\frac{n}{p_0 \cdot q_0}}\right)
\end{aligned}$$

Wir lösen für $\alpha = 0.05$ und $n = 100$ nach c auf und erhalten:

$$c \approx \sqrt{\frac{p_0 \cdot q_0}{n}}\Phi^{-1}\left(1 - \frac{\alpha}{2}\right) = 0.098$$

Mit Python:

```
n = 100
p_0 = 0.5; q_0=1-p_0
p_hat = 0.62
alpha = 0.05
c=np.sqrt(p_0 * q_0 / n) * stats.norm.ppf(1-alpha/2)
print(c)
```

Die Entscheidungsregel liefert wegen $0.62 - 0.5 = 0.12 \geq 0.098$ eine Verwerfung von H_0 zugunsten von H_1, also $\rightsquigarrow H_1$. Der statistische Test lehnt also die faire Münze als Erklärung für das beobachtete Ergebnis ab, wobei die Irrtumswahrscheinlichkeit (der Fehler 1. Art) höchstens 5% ist.

Würde man aber mit $\alpha = 0.01$ eine noch kleinere Irrtumswahrscheinlichkeit fordern, so ergibt sich $c = 0.1288$ und damit wegen $0.62 - 0.5 = 0.12 < 0.1288$ die Entscheidung $\rightsquigarrow H_0$. Wenn die Münze wirklich unfair ist wird eine geeignete Erhöhung der Versuchsanzahl n auch auf dem 1% Niveau eine Ablehnung zulassen.

Oft wird auch der sogenannte p-Wert

$$p^* = P[|\hat{p} - p_0| \geq \text{Beobachtung}] = 2 - 2\Phi\left((\text{Beobachtung} - p_0)\sqrt{\frac{n}{p_0 \cdot q_0}}\right) = 0.0164$$

angegeben, dieser liegt in unserem Fall genau zwischen den Signifikanzniveaus 5% und 1%. Der p^*-Wert gibt direkt die Wahrscheinlichkeit eines Fehlers 1. Art an wenn man sich für H_1 entscheidet. In Python berechnen wir den Wert mittels:

```
p_value = 2 - 2 * stats.norm.cdf((p_hat-p_0) *
                    np.sqrt(n/(p_0*q_0)))
```

Ausblick: Statistische Tests - eine Auswahl

Je nach Art des zur Formulierung der Hypothesen benutzen Modells müssen geeignete Teststatistiken gefunden werden und deren Verteilung analysiert werden. Für fast alle Standardanwendungen ist diese Arbeit bereits getan und in den in der Literaturliste angegebenen Büchern dokumentiert. Im Folgenden sind ein paar gängige Varianten zusammengefasst, zur Berechnung wird meistens die `scipy.stats` Library verwendet. **Aufgabenstellung:** Es seien eine oder zwei Stichproben $x_1, \ldots, x_n$ und $y_1, \ldots, y_m$ i.i.d. gegeben und es soll eine der folgenden Hypothesen geprüft werden, wobei in allen Fällen die Signifikanz des Testes gleich α*100% sein soll. Wenn das Kriterium der Entscheidungsregel nicht zutrifft wird H_0 nicht abgelehnt, ansonsten wird H_0 zugunsten von H_1 mit $(1-\alpha) * 100\%$tiger Sicherheit abgelehnt. Achtung: H_0 wird nie "bewiesen"!

Binomial-Test: Test für die Erfolgswahrscheinlichkeit p der bernoulliverteilten Grundgesamtheit

Beispiel: Ist die Münze fair? (Das ist nochmals der oben besprochene Test mit $p_0 = 1/2$)

Hypothese:	H_0: $p = p_0$ H_1: $p \neq p_0$
Statistik:	$z = \sqrt{\frac{n}{p_0 \cdot (1-p_0)}}(\hat{p} - p_0)$ wobei $\hat{p} = \frac{1}{n}\sum_i x_i$ die relative Häufigkeit der Erfolge in den Beobachtungen der Indikatoren $x_i \in \{0, 1\}$
Entscheidungsregel:	$\rightsquigarrow H_1$ wenn $\lvert z\rvert \geq \Phi^{-1}(1 - \frac{\alpha}{2})$
P-Wert:	$p^* = 2 - 2 \cdot \Phi(\lvert z\rvert)$
Python:	`scipy.stats.binom_test` oder folgender Code:

```
n = 100; success = 62
p_0 = 0.5; q_0=1-p_0
p_hat = success / n
alpha = 0.05
c=np.sqrt(p_0 * q_0 / n) * stats.norm.ppf(1-alpha/2)
print(c)
p_value = 2 - 2 * stats.norm.cdf((p_hat-p_0)*np.sqrt(n/(p_0*q_0)))
print(p_value)
```

Z-Test: Vergleich der Erfolgswahrscheinlichkeiten p_x, p_y zweier unverbundener Bernoulliverteilter Grundgesamtheiten

Beispiel: Ist die Fehlerquote zweier Übertragungsprotokolle gleich groß?

Hypothese:	H_0: $p_x = p_y$ H_1: $p_x \neq p_y$
Statistik:	$z = \frac{\hat{p}_x - \hat{p}_y}{\sqrt{\bar{p}\cdot(1-\bar{p})\cdot(1/n+1/m)}}$ wobei $\hat{p}_x, \hat{p}_y$ die relativen Anzahlen von Erfolgen in den Beobachtungen und $\bar{p} = \frac{n\cdot\hat{p}_x + m\cdot\hat{p}_y}{n+m}$
Entscheidungsregel:	$\rightsquigarrow H_1$ wenn $\lvert z\rvert \geq \Phi^{-1}(1-\frac{\alpha}{2})$
P-Wert:	$p^* = 2 - 2\cdot\Phi(\lvert z\rvert)$
Python:	Python Code: siehe unten

```
px_hat=...; n=...
py_hat=...; m=...
p_tilde=(px_hat*n+py_hat*m)/(n+m)
z=(px_hat-py_hat)/np.sqrt(p_tilde * (1-p_tilde) * (1/n + 1/m))
p_value = 2-2*stats.norm.cdf(np.abs(z))
print(p_value)
```

T-Test: Test für den Mittelwert μ der normalverteilten Grundgesamtheit bei unbekannter Standardabweichung

Beispiel: Ist der Messfehler eines Messgerätes im Mittel gleich Null, $\mu_0 = 0$ oder nicht? Die Standardabweichung ist nicht bekannt.

Hypothese:	H_0: $\mu = \mu_0$ vorgegeben H_1: $\mu \neq \mu_0$
Statistik:	$t = \sqrt{n} \cdot \frac{\bar{x}-\mu_0}{\hat{\sigma}}$ wobei $\bar{x}$ der Mittelwert der Beobachtungen und $\hat{\sigma} = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$ die geschätzte Standardabweichung
Entscheidungsregel:	$\rightsquigarrow H_1$ wenn $\lvert t\rvert \geq T_{n-1}^{-1}(1 - \frac{\alpha}{2})$
P-Wert:	$p^* = 2 - 2 \cdot T_{n-1}(\lvert t\rvert)$
Python:	`scipy.stats.ttest_1samp`

T-Test (unverbunden): Vergleich der Mittelwerte μ_x, μ_y zweier unverbundener normalverteilter Grundgesamtheiten bei unbekannter aber gleicher Standardabweichung $\sigma_x = \sigma_y$

Beispiel: Füllen 2 Abfüllanlagen im Mittel jeweils gleich viel Marmelade in Gläser? Die Standardabweichung wird als gleich vorausgesetzt.

Hypothese:	H_0: $\mu_x = \mu_y$ H_1: $\mu_x \neq \mu_y$
Statistik:	$t = \sqrt{\frac{n*m}{n+m}} \cdot \frac{\bar{x}-\bar{y}}{\bar{\sigma}}$ wobei $\bar{x}, \bar{y}$ die Mittelwert der Beobachtungen und $\bar{\sigma} = \sqrt{\frac{(n-1)\hat{\sigma}_x^2+(m-1)\hat{\sigma}_y^2}{n+m-2}}$ der geschätzte Mittelwert der empirischen Standardabweichung $\hat{\sigma}_x$ und $\hat{\sigma}_y$
Entscheidungsregel:	$\rightsquigarrow H_1$ wenn $\lvert t\rvert \geq T_{n+m-2}^{-1}(1 - \frac{\alpha}{2})$
P-Wert:	$p^* = 2 - 2 \cdot T_{n+m-2}(\lvert t\rvert)$
Python:	`scipy.stats.ttest_ind`

T-Test (verbunden): Vergleich der Mittelwerte μ_x, μ_y zweier verbundener normalverteilter Grundgesamtheiten bei unbekannter aber gleicher Standardabweichung $\sigma_x = \sigma_y$

Beispiel: Cholesterin-Wert von ProbandInnen in einer Studie vor und nach einer Diät.

Hypothese:	$H_0\colon \mu_x = \mu_y$
	$H_1\colon \mu_x \neq \mu_y$
Python:	`scipy.stats.ttest_rel`

Kapitel 6

Tabellen

6.1 Standardnormalverteilung $N_{0,1}$: $\Phi(x)$

	+0.00	+0.01	+0.02	+0.03	+0.04	+0.05	+0.06	+0.07	+0.08	+0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
	+0.00	+0.02	+0.04	+0.06	+0.08	+0.10	+0.12	+0.14	+0.16	+0.18
1.0	0.8413	0.8461	0.8508	0.8554	0.8599	0.8643	0.8686	0.8729	0.8770	0.8810
1.2	0.8849	0.8888	0.8925	0.8962	0.8997	0.9032	0.9066	0.9099	0.9131	0.9162
1.4	0.9192	0.9222	0.9251	0.9279	0.9306	0.9332	0.9357	0.9382	0.9406	0.9429
1.6	0.9452	0.9474	0.9495	0.9515	0.9535	0.9554	0.9573	0.9591	0.9608	0.9625
1.8	0.9641	0.9656	0.9671	0.9686	0.9699	0.9713	0.9726	0.9738	0.9750	0.9761
	+0.00	+0.05	+0.10	+0.15	+0.20	+0.25	+0.30	+0.35	+0.40	+0.45
2.0	0.9772	0.9798	0.9821	0.9842	0.9861	0.9878	0.9893	0.9906	0.9918	0.9929
2.5	0.9938	0.9946	0.9953	0.9960	0.9965	0.9970	0.9974	0.9978	0.9981	0.9984
3.0	0.9987	0.9989	0.9990	0.9992	0.9993	0.9994	0.9995	0.9996	0.9997	0.9997
3.5	0.9998	0.9998	0.9998	0.9999	0.9999	0.9999	0.9999	0.9999	1.0000	1.0000

6.2 Student-T-Verteilung T_n: $F^{-1}(p)$

n	0.9	0.95	0.975	0.99	0.995	0.999	n	0.9	0.95	0.975	0.99	0.995	0.999
1	3.078	6.314	12.706	31.821	63.657	318.309	16	1.337	1.746	2.120	2.583	2.921	3.686
2	1.886	2.920	4.303	6.965	9.925	22.327	17	1.333	1.740	2.110	2.567	2.898	3.646
3	1.638	2.353	3.182	4.541	5.841	10.215	18	1.330	1.734	2.101	2.552	2.878	3.610
4	1.533	2.132	2.776	3.747	4.604	7.173	19	1.328	1.729	2.093	2.539	2.861	3.579
5	1.476	2.015	2.571	3.365	4.032	5.893	20	1.325	1.725	2.086	2.528	2.845	3.552
6	1.440	1.943	2.447	3.143	3.707	5.208	22	1.321	1.717	2.074	2.508	2.819	3.505
7	1.415	1.895	2.365	2.998	3.499	4.785	24	1.318	1.711	2.064	2.492	2.797	3.467
8	1.397	1.860	2.306	2.896	3.355	4.501	25	1.316	1.708	2.060	2.485	2.787	3.450
9	1.383	1.833	2.262	2.821	3.250	4.297	29	1.311	1.699	2.045	2.462	2.756	3.396
10	1.372	1.812	2.228	2.764	3.169	4.144	30	1.310	1.697	2.042	2.457	2.750	3.385
11	1.363	1.796	2.201	2.718	3.106	4.025	40	1.303	1.684	2.021	2.423	2.704	3.307
12	1.356	1.782	2.179	2.681	3.055	3.930	50	1.299	1.676	2.009	2.403	2.678	3.261
13	1.350	1.771	2.160	2.650	3.012	3.852	100	1.290	1.660	1.984	2.364	2.626	3.174
14	1.345	1.761	2.145	2.624	2.977	3.787	200	1.286	1.653	1.972	2.345	2.601	3.131
15	1.341	1.753	2.131	2.602	2.947	3.733	∞	1.282	1.645	1.960	2.326	2.576	3.090

Literaturverzeichnis

[1] L. Papula. *Mathematische Formelsammlung*. Vieweg+Teubner, Braunschweig, Deutschland, 10. Auflage, 2001.

[2] M. Sachs. *Wahrscheinlichkeitsrechnung und Statistik für Ingenieurstudenten an Fachhochschulen*. Fachbuchverlag Leipzig im Carl Hanser Verlag, München, Wien, 3. Auflage, 2009.

[3] R. Storm. *Wahrscheinlichkeitsrechnung, mathematische Statistik und statistische Qualitätskontrolle*. Fachbuchverlag Leipzig, 2. Auflage, 2001.

[4] W. Voß. *Taschenbuch der Statistik*. Fachbuchverlag Leipzig im Carl Hanser Verlag, München, Wien, 2. Auflage, 2004.

[5] A. et. al. Croft. *Engineering Mathematics, A Foundation for Electronic, Electrical, Communications and Systems Engineers*. Pearson Prentice Hall, Edinburgh Gate, Harlow, England, third edition, 2001.

[6] A. Croft and R. Davison. *Mathematics for Engineers, A Modern Interactive Approach*. Pearson Prentice Hall, Edinburgh Gate, Harlow, England, second edition, 2004.